

**ДЕКОДИРОВАНИЕ ЛИНЕЙНЫХ БЛОКОВЫХ КОДОВ МЕТОДАМИ  
ГЛУБОКОГО ОБУЧЕНИЯ.**

**А. Э. Жданов, к.т.н.,**  
**[alexandr\\_zhdanov@mail.ru](mailto:alexandr_zhdanov@mail.ru)**

Канальное кодирование обеспечивает надежную связь по ненадежным, зашумленным каналам: кодируя сообщения с избыточностью, можно декодировать сообщения таким образом, что ошибки, вносимые каналом, исправляются. Разработка практических алгоритмов декодирования низкой сложности, которые могут обеспечить результаты, близкие к оптимальным для коротких кодов, все еще остается открытой проблемой.



Область применения: радиосистемы передачи данных с низкой задержкой, SDR, IoT, m2m.

Открытые библиотеки помехоустойчивых кодов (FEC) на github, сводная таблица:  
[https://aff3ct.github.io/fec\\_libraries.html](https://aff3ct.github.io/fec_libraries.html)

Линейный код (англ. Linear code) — код фиксированной длины (блоковый код), исправляющий ошибки, для которого любая линейная комбинация кодовых слов также является кодовым словом. Характеризуется порождающей матрицей  $G$  и проверочной матрицей  $H$ .


Входному вектору длиной  $k$  ставят в соответствие кодовое слово длиной  $n$ .

Кодовое слово при отсутствии ошибок при умножении на проверочную матрицу даст нулевой вектор.

Графически проверочная матрица может быть представлена как граф Таннера: двудольный граф.

$$\bar{s} \times G = \bar{x}, \bar{x} \times H = \bar{0}$$

Алгоритм итеративного декодирования на графе Таннера: offset min-sum  
(минимальной суммы с коррекцией)



$$Q_{n'm'} = \ln \left( \frac{P(1)}{P(0)} \right) + \sum_{m/n'} R_{m,n}$$

$$R_{m'n'} = \max \left( \min_{n/n'} (|Q_{m,n}|) - \beta, 0 \right) \prod_{n/n'} \text{sign}(Q_{m,n})$$

Достоинства:

- не требует умножений
- операции в целых числах с фиксированной разрядностью
- удобен в реализации
- реализует мягкое декодирование

Недостатки:


- только для кодов с низкой плотностью проверок на четность
- для остальных линейных блочных кодов не оптимален

Поэтому актуален neural min sum decoder (декодер с глубоким обучением)

$$R_{m'n'} = \max \left( \min_{n/n'} (|Q_{m,n}|) - \beta_{m'n'}, 0 \right) \prod_{n/n'} \text{sign}(Q_{m,n})$$


$\beta_{m'n'}$  -- параметр, подлежащий обучению, индивидуальный для каждого ребра графа Таннера

$$Q_{mn} = R_{mn} = 0$$




$$Q_{m'n'} = \ln\left(\frac{P(1)}{P(0)}\right) + \sum_m R_{n'm} - R_{m'n'}$$

Сообщение от  
переменного узла к  
проверочному узлу



$$R_{m'n'} = f(|Q_{m'n}|, \text{except } |Q_{m'n'}|) * \\ * [\prod_{n \neq n'} \text{sign}(Q_{m'n})]$$



Сообщение от  
проверочного узла к  
переменному узлу

**Известным** способом глубокого обучения является стохастический градиентный спуск, в частности оптимизатор Adam - adaptive moment estimation, использующий статистику второго порядка.

**Критичным** является выбор начального вектора параметров, подлежащего оптимизации, неудачный выбор может перечеркнуть дальнейшие усилия.





**Новым** является способ начальной инициализации, основанный на предобучении на графе, заключающийся в том, что если будут обнаружены дефекты графа Таннера в виде коротких циклов, то будет назначен большой штраф  $\beta_{m'n'}$

**Показано**, что декодер с выбранный таким образом начальным вектором параметров выдает одинаковые характеристики с известным обученным декодером.

**Ожидается**, что если провести глубокое обучение с правильно заданным вектором начальных параметров, то будет достигнут выигрыш по сравнению с известными решениями.

**Детали** даны на сайте проекта


<https://github.com/AlexandreZhdanov/Floding-neural-min-sum-decoder>



**Предобучение** состоит в следующих шагах:

1. Все узлы переводят в тренировочный режим в котором направленно распространяют единичное воздействие
2. Тестируемый узел начинает распространение, в остальных узлах устанавливают нули.
3. При приходе в узел единицы она транслируется в остальные ребра графа Таннера, но не в то ребро по которому осуществлено единичное воздействие.
4. При получении единичного отклика в тестируемый узел соответствующему ребру назначают большое значение предобучаемого параметра
5. Переходят к следующему узлу

# ДЕКОДИРОВАНИЕ ЛИНЕЙНЫХ БЛОКОВЫХ КОДОВ МЕТОДАМИ ГЛУБОКОГО ОБУЧЕНИЯ



Начальная инициализация происходит путем обучения на графе, при этом если будут обнаружены дефекты графа Таннера, то будет назначен большой  $\beta_{m,n}$

По результатам видно, что алгоритм с минимальным обучением выдает характеристики аналогичные алгоритму с глубоким обучением.

Цель: провести оптимизацию весов методом глубокого обучения, расширить множество кодов допускающих подобное декодирование:  
не менее 20 кодов для блоков от 20 -200 бит, расчетная задержка 1 мс

Характеристики offset min sum flooding алгоритма с минимальным обучением для кода BCH (63,36,11) и его сравнение с алгоритмом [10]

10. Loren Lugosch and Warren J Gross. Neural offset min-sum decoding. In 2017 IEEE International Symposium on Information Theory (ISIT), pages 1361–1365. IEEE, 2017.

14 D. Kingma and J. Ba, "Adam: A method for stochastic optimization," International Conference on Learning Representations, 2015.

Ссылка на репозиторий проекта:

<https://github.com/AlexandreZhdanov/Floding-neural-min-sum-decoder>

## Опыт

Жданов Александр Эдуардович (12 патентов, 67 свидетельств о регистрации программ)

Непосредственно по теме:

### Патенты и статьи

СПОСОБ ПЕРЕМЕЖЕНИЯ КОДОВЫХ СИМВОЛОВ В КОДЕ С НИЗКОЙ ПЛОТНОСТЬЮ ПРОВЕРОК НА ЧЕТНОСТЬ. Патент на изобретение 2755295 С1, 14.09.2021. Заявка № 2021100884 от 18.01.2021.

СИГНАЛЬНО-КОДОВАЯ КОНСТРУКЦИЯ ДЛЯ СВЕРХНАДЕЖНОЙ ПЕРЕДАЧИ ДАННЫХ НА ОСНОВЕ КОДА С ИРРЕГУЛЯРНЫМИ ПОВТОРЕНИЯМИ-НАКОПЛЕНИЯМИ Теория и техника радиосвязи. 2020. № 3. С. 83-88.

УСТРОЙСТВО ПЕРЕДАЧИ ДАННЫХ НА ОСНОВЕ КОДОВ С НИЗКОЙ ПЛОТНОСТЬЮ ПРОВЕРОК НА ЧЕТНОСТЬ Патент на изобретение RU 2713573 С1, 05.02.2020. Заявка № 2019117117 от 03.06.2019.

СПОСОБ ПЕРЕДАЧИ ДАННЫХ НА ОСНОВЕ КОДОВ С НИЗКОЙ ПЛОТНОСТЬЮ ПРОВЕРОК НА ЧЕТНОСТЬ Патент на изобретение RU 2708349 С1, 05.12.2019. Заявка № 2019117093 от 03.06.2019.

СПОСОБ ПЕРЕДАЧИ ДАННЫХ В СИСТЕМЕ ЦИФРОВОЙ РАДИОСВЯЗИ НА ОСНОВЕ КОДОВ С НИЗКОЙ ПЛОТНОСТЬЮ ПРОВЕРОК НА ЧЕТНОСТЬ И СПОСОБ ПЕРЕМЕЖЕНИЯ КОДОВЫХ СИМВОЛОВ Патент на изобретение RU 2700398 С1, 16.09.2019. Заявка № 2018147518 от 29.12.2018.

Ссылка на репозиторий проекта:

<https://github.com/AlexandreZhdanov/Floding-neural-min-sum-decoder>

### Программы для ЭВМ

СИМУЛЯТОР КОДА ПОВТОРЕНИЙ С НАКОПЛЕНИЯМИ Свидетельство о регистрации программы для ЭВМ RU 2019613042, 06.03.2019. Заявка № 2019611645 от 22.02.2019.

ПРОГРАММА МОДЕЛИРОВАНИЯ СТРУКТУРИРОВАННОГО КОДА С НИЗКОЙ ПЛОТНОСТЬЮ ПРОВЕРОК НА ЧЁТНОСТЬ НА ГРАФИЧЕСКОМ ПРОЦЕССОРЕ ОБЩЕГО НАЗНАЧЕНИЯ Свидетельство о регистрации программы для ЭВМ RU 2018665615, 06.12.2018. Заявка № 2018663042 от 21.11.2018.

ПРОГРАММА ПОИСКА ЦИКЛОВ В МАТРИЦЕ КОДОВ С МАЛОЙ ПЛОТНОСТЬЮ ПРОВЕРОК НА ЧЁТНОСТЬ Свидетельство о регистрации программы для ЭВМ RU 2018665616, 06.12.2018. Заявка № 2018663000 от 21.11.2018.

ПРОГРАММНЫЙ МОДУЛЬ КОДИРОВАНИЯ И ДЕКОДИРОВАНИЯ КОДА БОУЗ-ЧОУДХУРИ ХОКВИНГЕМА Свидетельство о регистрации программы для ЭВМ RU 2019613041, 06.03.2019. Заявка № 2019611577 от 22.02.2019.

ПРОГРАММА МОДЕЛИРОВАНИЯ ПЕРЕДАЧИ ГОЛОСОВЫХ ДАННЫХ В СИСТЕМЕ БЕСПРОВОДНОЙ РАДИОСВЯЗИ Свидетельство о регистрации программы для ЭВМ RU 2018665491, 05.12.2018. Заявка № 2018662039 от 02.11.2018.

ПРОГРАММА МОДЕЛИРОВАНИЯ СТРУКТУРИРОВАННОГО КОДА С НИЗКОЙ ПЛОТНОСТЬЮ ПРОВЕРОК НА ЧЁТНОСТЬ НА ГРАФИЧЕСКОМ ПРОЦЕССОРЕ ОБЩЕГО НАЗНАЧЕНИЯ Свидетельство о регистрации программы для ЭВМ RU 2018665615, 06.12.2018. Заявка № 2018663042 от 21.11.2018.

ПРОГРАММА МОДЕЛИРОВАНИЯ НЕБИНАРНОГО КОДА С НИЗКОЙ ПЛОТНОСТЬЮ ПРОВЕРОК НА ЧЁТНОСТЬ Свидетельство о регистрации программы для ЭВМ RU 2018664894, 26.11.2018. Заявка № 2018662059 от 02.11.2018.

Перспективы использования результатов по следующим направлениям:

- Ultra-Reliable and Low-Latency Communications (URLLC)
- Massive machine-type Communications (mMTC)